

UNIVERSIDAD SURCOLOMBIANA

Facultad de Ingeniería · Programa de Ingeniería de Software · Grupo 8 (Energía e Industria 4.0)

ElecPrevis · Entregable 2, Parte 1: Construcción del dataset

Electiva en Ingeniería Aplicada II (English and Data Science Fundamentals) · Ciencias de la Computación II
Juan Diego Montenegro Segura · Sofía Montaña · Nicolás Mosquera Perdomo · Neiva, septiembre de 2026

Control del documento

Versión	Fecha	Descripción	Elaboró
v1.0	Septiembre de 2026	Construcción del dataset: pipeline de limpieza, imputación causal, remuestreo a 30 minutos, variables temporales y verificación de balance.	Grupo 8
v1.1	Septiembre de 2026	Se agrega el análisis de asimetría con prescripción de transformación, la verificación de multicolinealidad entre predictores y la contrastación con los criterios de la clase de EDA.	Grupo 8

Tabla 1. Control de versiones de este documento.

1. Alcance de esta parte

El criterio de la rúbrica para esta entrega pide que la construcción del dataset esté balanceada acorde al problema y que supere los 35.000 registros. Este documento cubre exactamente ese criterio: de dónde salen los datos, cómo se limpiaron, cómo se convirtieron en variables útiles para el modelo y qué tan representativo quedó el conjunto final.

El resultado es un dataset supervisado de 68.840 registros por intervalo de 30 minutos, construido a partir de 2.075.259 mediciones minuto a minuto del dataset público Individual Household Electric Power Consumption de UCI. El conjunto cubre 24 horas del día, los 7 días de la semana y los 12 meses del año con un reparto prácticamente uniforme, sin valores nulos y con una partición temporal de entrenamiento y prueba que no se solapa.

El trabajo de modelado y simulación de esta entrega se documenta por separado. Aquí solo se llega hasta el dataset listo para entrenar.

2. Fuente de datos

2.1 Origen y características

Los datos vienen del repositorio de Machine Learning de la Universidad de California en Irvine (UCI), dataset 235: Individual Household Electric Power Consumption. El archivo contiene 2.075.259 mediciones registradas minuto a minuto entre el 16 de diciembre de 2006 y el 26 de noviembre de 2010 en una vivienda de Sceaux, Francia. Son 47 meses de operación continua con siete variables numéricas más la fecha y la hora.

La descarga reproduce el enlace oficial del repositorio y no depende de ningún archivo alojado por el equipo. El peso del comprimido es de 20 MB aproximadamente y el archivo descomprimido de 132 MB, motivo por el cual no se versiona en Git: cada integrante lo obtiene con el script del repositorio.

2.2 Diccionario de variables

Las siete variables numéricas del archivo original se describen en la Tabla 2. Las tres submediciones dividen el consumo en grupos de cargas domésticas y son la base del análisis de eficiencia del proyecto.

Variable	Descripción	Unidad
Global_active_power	Potencia activa media del minuto. Es la variable objetivo del proyecto.	kW
Global_reactive_power	Potencia reactiva media del minuto.	kW
Voltage	Tensión media del minuto.	V
Global_intensity	Intensidad media del minuto.	A
Sub_metering_1	Energía de cocina (principalmente lavavajillas, horno y microondas).	Wh
Sub_metering_2	Energía de lavandería (lavadora, secadora, nevera y luces).	Wh
Sub_metering_3	Energía de calentador de agua y aire acondicionado.	Wh

Tabla 2. Variables del dataset original de UCI. Fuente: descripción oficial del repositorio.

3. Proceso de construcción

La construcción sigue las tres etapas del proceso ETL que se trabajó en clase: extracción del archivo crudo, transformación con criterios justificados y carga del resultado en un archivo procesado. Todo el procedimiento vive en `src/preprocessing.py` y `src/features.py` del repositorio del proyecto.

3.1 Extracción

El archivo llega como un texto plano separado por punto y coma, con cabecera y con el carácter de interrogación como marcador de dato faltante. La lectura combina las columnas Date y Time en un único índice de tipo fecha y hora, ordena la serie y verifica una propiedad importante: los 2.075.258 intervalos entre mediciones son de un minuto exacto, sin huecos en el índice. Es decir, los datos faltantes están marcados dentro de las filas y no como filas ausentes.

3.2 Limpieza

Valores faltantes. El 1,252 % de las mediciones viene marcado como faltante, unas 25.979 lecturas de minuto repartidas en las siete columnas. Revisando cómo se agrupan esos huecos aparecen 71 interrupciones: 38 duran un solo minuto y 9 pasan de una hora, pero hay 6 cortes grandes asociados a fallas del equipo de medición, entre ellos uno de 7.226 minutos (cinco días) que empieza el 17 de agosto de 2010.




Figura 1. Los datos faltantes no se reparten de forma uniforme: 6 cortes del equipo concentran la mayor parte de los 25.979 minutos ausentes y el mayor dura cinco días (7.226 minutos). Prescripción: imputación causal por propagación, dejando ese tramo registrado como limitación.

Para rellenar esos huecos se usa propagación hacia adelante (forward fill): cada valor faltante toma la última observación válida. La decisión es deliberada. Una interpolación centrada rellenaría el hueco usando también el valor siguiente, y en un pronóstico a 30 minutos ese dato todavía no existe cuando el modelo tiene que predecir. Usar esa información sería fuga de datos temporales. El forward fill solo propaga lo ya observado, de modo que ninguna fila depende de información posterior. En total se rellenaron 181.853 celdas, el mismo 1,252 % de las celdas de las siete columnas numéricas.

Optimización de memoria. Un archivo de dos millones de filas en precisión doble ocupa más memoria de la necesaria para la información que guarda. Bajando las columnas numéricas a precisión simple el consumo pasó de 132,8 MB a 74,7 MB, una reducción del 43,8 % que deja el procesamiento cómodo en un equipo personal.

Valores atípicos. La Tabla 3 reporta los valores que caen fuera del rango intercuartílico. El diagnóstico se hizo sobre los datos crudos, antes de imputar, para no mezclar valores rellenados con valores medidos.

Variable	Q1	Q3	Límite inferior	Límite superior	Atípicos	%
Global_active_power	0,308	1,528	-1,522	3,358	94.907	4,63
Global_reactive_power	0,048	0,194	-0,171	0,413	40.420	1,97
Voltage	238,99	242,89	233,14	248,74	51.067	2,49
Global_intensity	1,400	6,400	-6,100	13,900	100.961	4,93
Sub_metering_1	0,000	0,000	0,000	0,000	169.105	8,25
Sub_metering_2	0,000	1,000	-1,500	2,500	77.151	3,77
Sub_metering_3	0,000	17,000	-25,500	42,500	0	0,00

Tabla 3. Valores atípicos por rango intercuartílico sobre los datos crudos. Los recuentos altos en las submediciones corresponden a su naturaleza discreta y a los ceros nocturnos, no a errores de medición.

Ningún atípico se recortó. Un pico de consumo puede ser un evento real, como encender el horno, y borrarlo sin criterio eliminaría justamente los episodios que el proyecto quiere estudiar. El criterio técnico que se trabajó en clase es el mismo: un valor atípico no se elimina automáticamente, se investiga si es un error de medición o un evento anómalo real. El diagnóstico queda documentado y el modelado lo trata con herramientas que toleran colas pesadas.

3.3 Remuestreo a 30 minutos

La resolución original es de un minuto, demasiado fina para el horizonte del proyecto y mucho más costosa de modelar. Se agregó por promedio en ventanas de 30 minutos, que es el horizonte que define el problema de investigación. Cada ventana queda etiquetada por su minuto inicial, de modo que la fila de la hora t resume el intervalo $[t, t+30)$ y no depende de nada posterior. El resultado son 69.177 intervalos sin un solo nulo.

La Figura 2 muestra cómo se ve la serie completa después del proceso. Se grafica el promedio diario para que cuatro años de datos entren en una sola vista.




Figura 2. Cuatro años de consumo diario. La media anual cae de 1,11 kW en 2007 a 1,05 kW en 2010, un descenso leve (5 %) frente al peso del ciclo anual. Prescripción: la partición temporal debe respetar el orden cronológico para que esa deriva no se filtre al entrenamiento.

3.4 Construcción de variables

El modelo no puede predecir con la sola serie de consumo. A partir del consumo por intervalo se construyen variables de calendario, variables cíclicas, rezagos y una media móvil, todas calculadas únicamente con información disponible hasta el instante de predicción. La Tabla 4 las resume.

Grupo	Variables	Para qué sirve
Calendario	hour, dayofweek, is_weekend, month	Capturan los ciclos del consumo doméstico: la hora del día, el día de la semana y el mes.
Cíclicas	hour_sin, hour_cos, month_sin, month_cos	Representan la hora y el mes como ciclos. Sin esto el modelo ve las 23:00 lejos de las 00:00 y diciembre lejos de enero.
Rezagos	Global_active_power_lag1, lag48, lag336	Consumo del intervalo anterior, del mismo intervalo del día anterior y de la semana anterior.
Media móvil	Global_active_power_roll_mean_48	Promedio de las últimas 24 horas, calculado con desplazamiento previo para no incluir la fila actual.
Objetivo	y	Consumo del intervalo siguiente, que es lo que el modelo debe predecir.

Tabla 4. Variables construidas y su función dentro del modelo.

Los rezagos no son arbitrarios. Con intervalos de 30 minutos, el rezago 1 es el intervalo inmediatamente anterior, el 48 corresponde al mismo intervalo del día anterior y el 336 a la misma franja de la semana anterior, porque $48 \times 7 = 336$. Esos tres horizontes son los que la literatura de pronóstico residencial identifica como los de mayor peso: inercia de corto plazo, ciclo diario y ciclo semanal.

Toda la construcción respeta una regla: ninguna variable puede usar información posterior al instante que se predice. Los rezagos usan desplazamiento hacia atrás y la media móvil se desplaza una posición antes de promediar. La partición de entrenamiento y prueba también es cronológica, nunca aleatoria.

3.5 Objetivo y partición temporal

El objetivo y se define como el consumo del intervalo siguiente, de manera que el problema queda planteado como pronóstico de un paso con horizonte de 30 minutos. La partición reserva el 20 % final de la serie para prueba: 55.072 registros para entrenamiento, del 23 de diciembre de 2006 al 13 de febrero de 2010, y 13.768 para prueba, del 13 de febrero al 26 de noviembre de 2010. Las dos particiones no comparten ni un registro, y la prueba cae en el tramo final del periodo, que es la condición realista de operación.

3.6 Carga del resultado

El dataset procesado se guarda en data/processed/power_30min.csv, con un peso de 5,3 MB, índice de fecha y hora y las siete variables remuestreadas. El dataset supervisado con las variables construidas se genera en memoria con una función del repositorio, de modo que cualquier integrante reproduce el mismo conjunto ejecutando dos comandos.

4. Dataset resultante y verificación de balance

La rúbrica pide un dataset balanceado acorde al problema. En un problema de regresión sobre series de tiempo no hay clases que balancear, así que la verificación se hace sobre dos propiedades que sí importan aquí: que el conjunto cubra de manera uniforme los ciclos que el modelo debe aprender y que las particiones de entrenamiento y prueba sean comparables entre sí.

4.1 Tamaño y composición

El dataset supervisado final tiene 68.840 registros y 20 columnas: 19 variables de entrada y el objetivo. Durante la construcción se descartan 337 filas iniciales porque los rezagos largo y la media móvil necesitan historia previa, y la última fila porque su objetivo no existe. El conteo final más que duplica el mínimo de 35.000 registros que exige la rúbrica.

4.2 Estadísticos descriptivos y asimetría

La Tabla 5 compara el consumo por intervalo en el conjunto completo y en cada partición, e incorpora el coeficiente de asimetría. Los valores de entrenamiento y de prueba son cercanos en todos los estadísticos, lo que indica que la partición temporal no dejó una de las dos mitades en un régimen de consumo distinto.

Conjunto	Registros	Media	Desv.	Sesgo	Mín.	Mediana	P75	Máx.
Serie completa	69.177	1,086	0,948	1,442	0,088	0,711	1,563	7,876
Entrenamiento	55.072	1,106	0,981	1,416	0,088	0,713	1,593	7,876
Prueba	13.768	0,989	0,781	1,369	0,146	0,685	1,477	6,245

Tabla 5. Estadísticos descriptivos del consumo por intervalo de 30 minutos, en kW. La media de prueba es ligeramente menor que la de entrenamiento, una diferencia esperable en series reales.

El coeficiente de asimetría del objetivo es 1,44, un valor que la clase de EDA clasifica como asimetría positiva severa (por encima de 1). La media (1,083 kW) queda por encima de la mediana (0,707 kW), el 43,3 % de los intervalos se queda por debajo de 0,5 kW y la cola llega hasta 7,876 kW, con un percentil 95 de 2,95 kW y un percentil 99 de 4,17 kW. La distribución tiene muchos valores bajos y pocos valores altos, que es la firma del consumo doméstico.

La consecuencia práctica es la que se señaló en clase: los modelos sensibles a colas pesadas, como la regresión lineal, rinden peor sin tratamiento. Por eso el objetivo se transforma con $\log(1 + y)$ antes de ajustar el modelo lineal y las métricas se reportan de vuelta en kW para que sean comparables. Los modelos de árboles, como random forest y XGBoost, no requieren la transformación porque sus divisiones son invariantes ante cambios monótonos de escala. La decisión queda registrada aquí y se aplica en la parte de modelado.

El consumo es asimétrico: la media (1,08 kW) supera la mediana (0,71 kW), skew = 1,44




Figura 3. Tres vistas de la misma variable: histograma con densidad KDE, función de distribución acumulada y boxplot. La media (1,08 kW) supera la mediana (0,71 kW) y la lectura acumulada confirma que el 56,4 % de los intervalos se queda por debajo de 1 kW. Prescripción: $\log(1 + y)$ para el modelo lineal.

4.3 Cobertura de los ciclos temporales

La Tabla 6 verifica el balance por ciclo. El reparto por hora es exactamente uniforme: cada una de las 24 horas concentra el 4,17 % de los registros. En los días de la semana el mínimo es 14,24 % y el resto se reparte en torno al 14,29 %. Los meses oscilan entre 7,06 % y 8,65 %, una variación normal porque el periodo no arranca en enero.

Ciclo	Categorías cubiertas	Reparto de registros	Veredicto
Hora del día	24 de 24	4,17 % en cada hora	Uniforme
Día de la semana	7 de 7	14,24 % el mínimo, cerca del 14,29 % esperado	Uniforme
Mes	12 de 12	entre 7,06 % y 8,65 %	Equilibrado
Año	2007 a 2010	17.520, 17.568, 17.520 y 15.834 registros	Equilibrado

Tabla 6. Balance del dataset supervisado por ciclo temporal. El año 2006 solo aporta 398 registros porque el periodo arranca el 23 de diciembre.




Figura 4. El consumo se cuadruplica entre el valle de las 04:00 (0,45 kW) y el pico de las 20:00 (1,89 kW). Prescripción: la hora entra al modelo codificada como ciclo, no como número lineal.




Figura 5. El patrón horario se repite los siete días con la misma forma, y el fin de semana adelanta el pico hacia la tarde. Confirma que las variables de hora y día de la semana aportan información no redundante para el modelo.




Figura 6. El consumo medio de diciembre (2,55 veces el de agosto) confirma un ciclo anual fuerte. Prescripción: la partición de prueba cubre once meses del año, de modo que el modelo no se evalúe solo en una estación.




Figura 7. Entrenamiento y prueba comparten forma y media (1,106 kW y 0,989 kW). Verificación: la partición cronológica no introdujo un cambio de régimen, condición para que las métricas de la parte de modelado sean interpretables.

4.4 Relación de las variables con el objetivo

La siguiente verificación revisa que las variables construidas tengan relación real con el objetivo. La potencia activa del instante actual y la intensidad son las más correlacionadas, lo que tiene sentido físico porque una se deriva de la otra. Detrás aparecen el rezago inmediato, la submedición del calentador y del aire acondicionado, y los ciclos diario y semanal. El voltaje es la única variable que correlaciona de forma negativa.

La figura incluye los dos coeficientes que se trabajaron en clase. Pearson mide asociación lineal y Spearman mide asociación monótona sobre los rangos, más robusto ante valores atípicos. En el rezago de 30 minutos Spearman (0,685) supera a Pearson (0,621), señal de que la relación es monótona pero no estrictamente lineal. En la submedición de lavandería ocurre lo contrario y con más fuerza: Pearson da 0,284 y Spearman apenas 0,119, así que buena parte de esa correlación aparente la sostienen unos pocos picos aislados y no una relación continua.




Figura 8. Correlación de cada variable con el consumo del siguiente intervalo, medida con Pearson (barras) y Spearman (puntos). Cuando los dos coeficientes se separan, el vínculo es monótono sin ser lineal y conviene apoyarse en modelos no lineales.

4.5 Verificación de multicolinealidad

El último control revisa si alguna pareja de predictores mide dos veces la misma cosa, porque la redundancia severa desestabiliza los coeficientes de un modelo lineal y vuelve ilegible la importancia de las variables. El criterio que se fijó en clase es descartar candidatas cuando el valor absoluto de la correlación supera 0,85. La revisión de las 15 variables de entrada deja un solo caso, y es claro.

Par de variables	Pearson	Spearman	Decisión
Global_active_power y Global_intensity	0,999	0,997	Se conserva Global_active_power: es la serie del objetivo y sostiene la estructura autorregresiva. Global_intensity queda como candidata a descarte en el modelo lineal y se documenta en la parte de modelado.

Tabla 7. Candidatas a descarte por multicolinealidad (umbral $|r| > 0,85$). Ninguna otra pareja de las 15 variables de entrada supera el umbral.

El motivo físico es directo: la intensidad se obtiene de la potencia y la tensión, así que las dos variables son la misma señal expresada en unidades distintas. En los modelos de árboles la redundancia no degrada el desempeño, porque el ensamble reparte la importancia entre ambas sin perder capacidad predictiva, pero sí distorsiona la lectura de qué variable pesa más. La decisión se tomará de forma explícita en la comparación de modelos, no se dejará al azar.

Multicolinealidad: Global_active_power y Global_intensity son redundantes ($|r| > 0,85$)




Figura 9. Izquierda: matriz de correlación en triángulo, con la mitad repetida oculta para reducir ruido visual. Derecha: las dos variables redundantes en una submuestra de 4.000 puntos con transparencia, porque con 68.840 puntos un gráfico completo ocultaría la densidad.

5. Trazabilidad del proceso

Cada paso de la construcción quedó con su comando y su salida verificada, de manera que cualquier integrante puede reproducir la misma cifra desde el archivo original. La Tabla 8 recoge esa cadena.

Paso	Comando o función	Salida verificada
Descarga del archivo	python src/download_data.py	household_power_consumption.txt (132 MB, enlace oficial de UCI)
Lectura y limpieza	load_raw() + optimize_memory()	2.075.259 filas, índice continuo de un minuto, 132,8 MB a 74,7 MB

Imputación causal	impute_missing() con forward fill	181.853 celdas rellenadas, 1,252 % del total, sin mirar al futuro
Remuestreo	resample_30min()	69.177 intervalos de 30 minutos, sin nulos
Variables	build_supervised_dataset()	19 variables de entrada y el objetivo, sin información futura
Partición temporal	temporal_train_test_split()	55.072 registros de entrenamiento y 13.768 de prueba, sin solape
Multicolinealidad	corr() sobre las 15 variables de entrada	1 pareja sobre el umbral: Global_active_power y Global_intensity (r = 0,999)

Tabla 8. Trazabilidad de la construcción del dataset.

6. Cumplimiento del criterio de rúbrica

Exigencia del nivel alto	Resultado del proyecto	Estado
Dataset balanceado acorde al problema	Reparto uniforme en los ciclos horario, semanal y mensual, con particiones comparables	Cumplido
Más de 35.000 registros	68.840 registros supervisados por intervalo de 30 minutos	Superado

Tabla 9. Verificación del criterio Construcción del Dataset de la rúbrica del Entregable 2.

7. Contrastación con los criterios de la clase (EDA)

La sesión de análisis exploratorio cerró con una lista de verificación. La Tabla 10 la responde para este dataset, de modo que la revisión no quede solo en el código sino también en el documento.

Pregunta de la clase	Respuesta para este dataset
¿Los gráficos respetan la naturaleza de los datos (categórico vs. continuo)?	Sí. Las variables continuas se muestran con histograma, KDE, ECDF y boxplot; el ciclo mensual con barras; y la relación entre hora y día de la semana con un mapa de calor.
¿Los ejes tienen unidades claras y títulos descriptivos?	Sí. Cada eje lleva su unidad en kW, A o V, y los títulos enuncian el hallazgo en lugar del tipo de gráfico.
¿Se identificaron posibles candidatas a descartar por multicolinealidad?	Sí. Una pareja supera el umbral de 0,85: Global_active_power y Global_intensity, con r = 0,999 de Pearson y 0,997 de Spearman. La decisión queda registrada en la Tabla 7.
¿Se mantiene la consistencia con el balanceo de clase de la Semana 6?	No aplica un balanceo de clases porque este es un problema de regresión, no de clasificación. En su lugar se verifica el balance de los ciclos temporales y la comparabilidad de las particiones, en la sección 4.3.

Tabla 10. Respuestas al checklist de la sesión de análisis exploratorio.

8. Limitaciones de la construcción

Tres limitaciones conviene dejarlas escritas antes de pasar al modelado. La primera es que el dataset corresponde a una sola vivienda en Francia y a un periodo entre 2006 y 2010, así que sus patrones no representan el consumo colombiano ni el consumo actual. El proyecto lo asume como un caso de estudio metodológico y no extrapola sus cifras a otros contextos.

La segunda es que las tres submediciones cubren el 48,7 % de la energía activa total: la submedición 3 (calentador y aire acondicionado) aporta el 35,4 %, la de lavandería el 7,1 % y la de cocina el 6,1 %. El resto corresponde a cargas que el equipo original no monitoreó. Los escenarios de eficiencia se limitan por tanto a los grupos de carga que sí están medidos.

La tercera es la imputación. El 1,252 % de los datos fue rellenado por propagación, y en el hueco más largo (cinco días de agosto de 2010) esa propagación mantiene un valor constante durante todo el tramo. Es una consecuencia aceptada de la decisión de no mirar al futuro, y queda registrada para que el análisis de resultados no lea ese tramo como consumo real.