

ElecPrevis · Entregable 2, Parte 2: Selección de modelos de Machine Learning

Electiva en Ingeniería Aplicada II (English and Data Science Fundamentals) · Ciencias de la Computación II
Juan Diego Montenegro Segura · Sofía Montaña · Nicolás Mosquera Perdomo · Neiva, septiembre de 2026

Control del documento

Versión	Fecha	Descripción	Elaboró
v1.0	Septiembre de 2026	Selección de los cuatro modelos, fundamento matemático de cada uno, criterios de descarte, protocolo de validación temporal y trazabilidad con el estado del arte.	Grupo 8

Tabla 1. Control de versiones de este documento.

1. Alcance de esta parte

La rúbrica pide cuatro modelos de machine learning acordes a la solución, con estado del arte claro y soporte en el marco teórico. Este documento justifica la selección de esos cuatro modelos, escribe el fundamento matemático de cada uno, explica por qué se descartaron otras alternativas y define el protocolo con el que se van a comparar.

Los cuatro modelos elegidos son la regresión lineal, el random forest, XGBoost y la LSTM. Cubren un espectro deliberado de complejidad, que es justamente lo que exige la pregunta de investigación del proyecto: comparar alternativas de distinta complejidad bajo un mismo protocolo de validación. Los resultados numéricos de esa comparación se reportan en la parte de simulación.




Figura 1. Ubicación de los cuatro modelos en el plano de costo computacional e interpretabilidad. La regresión lineal actúa como punto de referencia: si un modelo complejo no la supera con claridad, su costo no se justifica.

2. Criterios de selección

La selección no se hizo por popularidad de los algoritmos sino por cinco criterios que se derivan del problema y del estado del arte revisado en el Entregable 1:

- Cobertura del espectro de complejidad. La pregunta de investigación compara modelos de distinta complejidad, así que el conjunto debe incluir desde una recta hasta una red recurrente.
- Adecuación a series temporales de alta frecuencia. El problema tiene dependencia temporal fuerte, y no todos los algoritmos la aprovechan igual.
- Respaldo en la literatura reciente. Cada modelo aparece al menos una vez en el estado del arte del Entregable 1 aplicado a pronóstico de carga eléctrica.
- Costo de cómputo razonable. El proyecto corre en equipos personales, sin GPU dedicada.
- Trazabilidad metodológica. Uno de los cuatro debe ser un punto de referencia simple e interpretable, porque una comparación sin línea base no dice nada.

La Tabla 2 resume cómo cada modelo responde a esos criterios.

Modelo	Familia	Complejidad	Interpretabilidad	Cumple
Regresión lineal	Paramétrico, lineal	Muy baja	Alta: coeficientes directos	5 de 5
Random forest	Ensamble de árboles	Media	Media: importancia de variables	5 de 5
XGBoost	Boosting de gradiente	Media alta	Media: importancia y SHAP	5 de 5
LSTM	Red neuronal recurrente	Alta	Baja: caja negra	5 de 5

Tabla 2. Modelos seleccionados y su posición frente a los criterios de selección.

3. Fundamento de los modelos seleccionados

3.1 Regresión lineal múltiple como punto de referencia

Es el modelo más simple del conjunto y cumple una función específica: establecer el piso de desempeño. Si un modelo de mayor complejidad no mejora de forma clara lo que logra una recta, su costo de cómputo y su pérdida de interpretabilidad no se justifican. La forma del modelo es una combinación lineal de las variables de entrada:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

Los coeficientes se estiman por mínimos cuadrados ordinarios, que en forma matricial se escriben así:

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

Dos tratamientos acompañan a este modelo y no a los demás. El primero es la estandarización de las entradas, necesaria para que la penalización implícita del ajuste no dependa de la unidad de cada variable. El segundo es la transformación del objetivo, porque el consumo tiene asimetría positiva severa ($\text{skew} = 1,44$) y los mínimos cuadrados quedan dominados por los pocos intervalos de consumo alto:

$$y' = \ln(1 + y) \quad \hat{y} = e^{\hat{y}'} - 1$$

La predicción se devuelve a kilovatios con la exponencial inversa, de modo que las métricas de este modelo sean comparables con las de los otros tres. En el estado del arte, las revisiones de pronóstico de carga sitúan a los métodos estadísticos y lineales como la línea base contra la que se mide cualquier avance [1], [6].

Nota sobre multicolinealidad: la verificación de la Parte 1 detectó que `Global_intensity` y `Global_active_power` son redundantes ($r = 0,999$). En un modelo lineal esa redundancia vuelve inestables los coeficientes, así que para esta rama se conserva la potencia activa y se excluye la intensidad. La decisión no se extiende a los modelos de árboles, que reparten la importancia sin degradar su desempeño.

3.2 Random forest

El random forest construye muchos árboles de decisión sobre muestras bootstrap del conjunto de entrenamiento y promedia sus predicciones. El promedio reduce la varianza que tendría un árbol individual sin aumentar el sesgo de forma apreciable, y la selección aleatoria de variables en cada división descorrelaciona los árboles. La predicción es:

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B T_b(x)$$

Cada árbol se parte buscando la división que más reduce la impureza de las hojas, medida en regresión con el error cuadrático:

$$I(G) = 1 - \sum_{k=1}^K p_k^2$$

Para este proyecto el atractivo del método es doble. Tolera bien los valores atípicos que el dataset tiene por naturaleza (picos de consumo reales) y entrega una medida de importancia de variables, que permite contrastar si el modelo está usando las señales que el análisis exploratorio identificó. No requiere escalado ni transformar el objetivo, porque sus divisiones son invariantes ante cambios monótonos de escala. Aparece en el estado del arte combinado con arquitecturas profundas para consumo de edificios [11] y en comparaciones de pronóstico residencial [5].

3.3 XGBoost

XGBoost también es un ensamble de árboles, pero en lugar de construirlos en paralelo los construye en secuencia, donde cada árbol nuevo corrige el error del conjunto anterior. La predicción se forma sumando esas correcciones con una tasa de aprendizaje que controla cuánto aporta cada árbol:

$$F_m(x) = F_{m-1}(x) + \nu h_m(x), \quad 0 < \nu \leq 1$$

Lo que distingue al método es la función objetivo que optimiza, porque incluye un término de regularización sobre la complejidad de los árboles además del error de predicción:

$$\mathcal{L} = \sum_{i=1}^n \ell(y_i, \hat{y}_i) + \sum_{k=1}^M \Omega(f_k)$$

Ese término es lo que evita que el modelo memorice el ruido de la serie, un riesgo real cuando se trabaja con 68.840 registros. Igual que el random forest, no necesita escalado. Su presencia en el estado del arte es la más fuerte de los cuatro: se reporta como referencia en pronóstico de carga a corto plazo [10] y dentro de esquemas interpretables que combinan boosting con redes de atención [15].

3.4 LSTM

La red LSTM es un tipo de red recurrente diseñada para recordar dependencias largas sin que el gradiente se desvanezca. En lugar de una neurona simple, cada celda mantiene un estado interno que se actualiza a través de tres compuertas: una decide qué olvidar del estado anterior, otra qué información nueva incorporar y la tercera qué parte del estado se expone como salida.

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad o_t = \sigma(W_o[h_{t-1}, x_t] + b_o)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tanh(W_C[h_{t-1}, x_t] + b_C)$$

$$h_t = o_t \odot \tanh(C_t)$$

La entrada del modelo son ventanas de 48 pasos consecutivos, equivalentes a las últimas 24 horas de consumo, con las 19 variables de la Parte 1 en cada paso. Es la arquitectura que mejor aprovecha la naturaleza temporal del problema, y por eso cierra el extremo de mayor complejidad de la comparación.

Arquitectura de la LSTM, con entrada estandarizada y salida en kW



La ventana de 48 pasos equivale a las últimas 24 horas de consumo a resolución de 30 minutos.

Figura 2. Arquitectura de la LSTM: ventana de 48 pasos por 19 variables, una capa recurrente de 64 unidades, una capa densa de 32 y la salida escalar en kW.

Los datos se estandarizan con la media y la desviación del conjunto de entrenamiento, porque sin ese paso la red recibe variables en rangos muy distintos (tensión alrededor de 240 frente a submediciones alrededor de 1) y el descenso de gradiente no converge bien. El objetivo recibe el mismo tratamiento que en la regresión lineal: se ajusta sobre $\log(1 + y)$ y se devuelve a kilovatios al predecir. La razón es doble, el consumo no puede ser negativo y su asimetría concentra el error en los picos, de modo que una capa de salida lineal sin límite inferior devuelve valores imposibles y aplana los máximos. Como cierre, la predicción se recorta en cero para descartar cualquier consumo negativo que sobreviva a la inversión del logaritmo. La semilla se fija en un único lugar del código para que el resultado se pueda repetir. En el estado del arte las redes recurrentes y convolucionales aparecen como la familia dominante del pronóstico reciente [13], [14], con variantes que mejoran su desempeño mediante especialización posterior al entrenamiento [12].

4. Alternativas consideradas y descartadas

La selección también se defiende mostrando qué quedó fuera y por qué. Tres de los modelos descartados aparecen en el temario del curso, así que conviene dejar escrito el motivo.

Alternativa	Motivo del descarte
K-Nearest Neighbors (KNN)	Su predicción exige recorrer el conjunto de entrenamiento completo para cada consulta. Con 55.072 registros de entrenamiento y 19 variables el costo por predicción es alto, y en dimensión alta la noción de vecindad pierde sentido.
Máquinas de vectores de soporte (SVM)	El entrenamiento con kernel crece de forma cuadrática con el número de muestras. Con 55.072 registros el costo es desproporcionado frente a alternativas que logran mejor desempeño en datos tabulares.
Prophet y modelos de suavizado	Están pensados para series univariadas con estacionalidades fijas. El proyecto necesita incorporar las submediciones y las variables exógenas construidas, que estos modelos no aprovechan.
Transformers	Su costo de entrenamiento es mucho mayor que el de una LSTM y el proyecto corre en equipos personales sin GPU dedicada. Se mencionan en el estado del arte [13] como línea de trabajo futuro.

Tabla 3. Alternativas evaluadas y motivo por el que no entran en la comparación.

5. Protocolo de comparación

Los cuatro modelos se evalúan con el mismo protocolo. La comparación solo es válida si las condiciones son idénticas, y eso incluye la partición de los datos, la forma de validar y las métricas.

5.1 Partición de los datos

La partición es cronológica, nunca aleatoria, porque mezclar registros al azar dejaría intervalos futuros en el entrenamiento y el modelo aprendería a copiar el futuro. El 80 % inicial de la serie se reserva para entrenamiento (55.072 registros, del 23 de diciembre de 2006 al 13 de febrero de 2010) y el 20 % final para prueba (13.768 registros, hasta el 26 de noviembre de 2010).

5.2 Validación de ventana expansiva

Sobre la partición de entrenamiento se corre una validación de ventana expansiva en cinco cortes. En cada corte el modelo se entrena con todo lo disponible hasta ese punto y se evalúa en el bloque inmediatamente siguiente, que nunca vio. El entrenamiento crece y el bloque evaluado avanza en el tiempo, que es la forma de simular cómo se comportaría el modelo en operación real.




Figura 3. Esquema de los cinco cortes de validación. El bloque evaluado siempre es posterior al entrenamiento, así que ninguna métrica proviene de información futura.

Una sola partición no basta para concluir que un modelo es mejor: puede caer en un periodo tranquilo o en uno difícil y el resultado sería casualidad. Reportar el promedio y la dispersión entre los cinco cortes es lo que sostiene la conclusión de la comparación.

5.3 Métricas de evaluación

Se reportan cuatro métricas porque cada una responde a una pregunta distinta. El error absoluto medio indica cuánto se equivoca el modelo en promedio, en las mismas unidades de la variable:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

La raíz del error cuadrático medio castiga con más fuerza los errores grandes, que en consumo eléctrico son los que más cuestan operativamente:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

El coeficiente de determinación dice qué fracción de la variabilidad del consumo queda explicada por el modelo, con el cero como referencia de un modelo que siempre predice el promedio:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Y el error porcentual simétrico permite comparar el desempeño entre franjas de consumo muy distintas, porque en consumo doméstico un error de 0,3 kW pesa mucho en la madrugada y poco en la hora pico:

$$\text{sMAPE} = \frac{100}{n} \sum_{i=1}^n \frac{2 |y_i - \hat{y}_i|}{|y_i| + |\hat{y}_i|}$$

5.4 Tratamiento de datos por modelo

Las diferencias de la Tabla 4 no son arbitrarias: cada una responde a cómo el algoritmo aprende. Los modelos basados en divisiones son indiferentes a la escala, los basados en distancias y en gradiente no lo son, y la transformación del objetivo solo aporta cuando el ajuste es lineal.

Modelo	¿Escalado?	¿Transforma y?	Observación
Regresión lineal	Sí, estandarización	Sí, $\log(1 + y)$	Se excluye Global_intensity por multicolinealidad
Random forest	No	No	Divisiones invariantes a la escala
XGBoost	No	No	Igual que el random forest; la regularización controla el sobreajuste
LSTM	Sí, estandarización	Sí, $\log(1 + y)$	Escala ajustada solo con el entrenamiento; la predicción se recorta en cero

Tabla 4. Preprocesamiento aplicado a cada modelo dentro del protocolo común.

5.5 Reproducibilidad

Todas las semillas se fijan en un solo punto del código, incluidas las de la red neuronal, que suelen quedar fuera del control de versiones de la mayoría de los proyectos. Ejecutar el mismo comando sobre el mismo dataset produce las mismas cifras, que es la condición para que la comparación signifique algo.

6. Trazabilidad con el estado del arte

Cada modelo tiene al menos una referencia del estado del arte que respalda su uso en pronóstico de carga, y las referencias se numeran igual que en el Entregable 1 para que los dos documentos se puedan leer juntos.

Modelo	Rol en la investigación	Referencias que lo respaldan
Regresión lineal	Punto de referencia interpretable y piso de desempeño	[1], [6]
Random forest	No lineal robusto ante atípicos, con importancia de variables	[11], [5]
XGBoost	Referencia del estado del arte en datos tabulares	[10], [15]
LSTM	Captura de la dependencia temporal larga de la serie	[13], [14], [12]
Dataset y contexto	Origen de los datos y del caso de estudio residencial	[4], [8], [9]

Tabla 5. Correspondencia entre cada modelo, su papel en el proyecto y las referencias del Entregable 1.

7. Cumplimiento del criterio de rúbrica

Exigencia del nivel alto	Resultado del proyecto	Estado
Selección de 4 modelos acordes a la solución	Regresión lineal, random forest, XGBoost y LSTM, elegidos por cinco criterios explícitos y cubriendo el espectro de complejidad que pide la pregunta de investigación	Cumplido
Estado del arte claro	Cada modelo tiene al menos una referencia del estado del arte del Entregable 1 que respalda su uso, con la trazabilidad en la Tabla 5	Cumplido
Soportado en el marco teórico	Fundamento matemático de cada modelo con sus ecuaciones, y justificación del preprocesamiento diferenciado de la Tabla 4	Cumplido

Tabla 6. Verificación del criterio Selección de Modelos ML de la rúbrica del Entregable 2.

8. Limitaciones de la selección

Dos limitaciones conviene dejarlas escritas. La primera es que la lista de cuatro modelos no agota el espacio de alternativas: deja fuera familias completas, como los modelos híbridos y los basados en atención, que la literatura reporta con buen desempeño y que quedan como trabajo futuro. La segunda es que la comparación se hace sobre un único hogar y un único periodo, así que las conclusiones sobre qué modelo conviene son válidas para este caso de estudio y no se pueden generalizar sin volver a medir.

También conviene ser explícito en algo que la pregunta de investigación no pide pero el lector podría esperar: la comparación mide desempeño predictivo, no valor económico. Que un modelo reduzca el error en un 20 % no implica que reduzca la factura en la misma proporción, y esa diferencia se discute en la parte de simulación.